

FACULDADE FAESA

PROJETO PRÁTICO C3 – BUSINESS INTELLIGENCE

Integração do Data Warehouse, ETL e Dashboard Analítico para Dados de
COVID-19

Aluno: Renan Miguel

Disciplina: Business Intelligence

Professor: Otávio Lube Dos Santos

Vitória – ES

2026

Sumário

1	Introdução	2
2	Modelagem Dimensional	2
2.1	Tabela Fato	2
2.2	Tabelas Dimensão	3
3	Processo ETL	3
3.1	Extract	3
3.2	Transform	4
3.3	Load	4
4	Integração do Streamlit com o Data Warehouse	4
5	Dashboard Analítico	5
5.1	Indicadores Gerais	5
5.2	Distribuição por Classificação	5
5.3	Distribuição por Sexo	5
5.4	Evolução Temporal	5
5.5	Top Municípios	5
5.6	Indicadores de Letalidade	6
6	Análise de Desempenho	6
6.1	Resultados Obtidos	6
6.2	Comparação	6
6.3	Escalabilidade	6
7	Conclusão	7

1 Introdução

O presente projeto tem como objetivo consolidar os conhecimentos adquiridos ao longo da disciplina de Business Intelligence por meio da integração das etapas desenvolvidas anteriormente. Na etapa C1 foi construída uma camada de visualização utilizando Streamlit e leitura direta de arquivos CSV. Na etapa C2 foi desenvolvido um Data Warehouse utilizando modelagem dimensional e processos de carga dos dados.

Nesta etapa final (C3), o objetivo foi concluir o Data Warehouse, finalizar o processo ETL e migrar a camada de visualização para consumir os dados diretamente do banco de dados analítico. Além disso, foi realizada uma comparação de desempenho entre a abordagem baseada em arquivos CSV e a abordagem baseada em Data Warehouse.

2 Modelagem Dimensional

Para o armazenamento analítico dos dados foi utilizado um modelo dimensional do tipo Esquema Estrela (Star Schema), amplamente empregado em soluções de Business Intelligence devido à sua simplicidade e eficiência em consultas analíticas.

O modelo foi composto por uma tabela fato central e diversas tabelas dimensão responsáveis por armazenar informações descritivas dos registros.

2.1 Tabela Fato

fato_notificacao_covid

Responsável por armazenar os eventos de notificação de COVID-19 e suas métricas, incluindo:

- Quantidade de notificações;
- Casos confirmados;
- Óbitos;
- Internações;
- Casos de cura;
- Idade do paciente;
- Intervalos entre datas de notificação, encerramento e óbito.

2.2 Tabelas Dimensão

Foram criadas as seguintes dimensões:

- dim_tempo
- dim_localidade
- dim_perfil_paciente
- dim_classificacao
- dim_sintomas
- dim_comorbidade
- dim_teste

Cada dimensão utiliza chaves substitutas (Surrogate Keys), permitindo melhor desempenho e independência em relação aos dados operacionais.

A dimensão Tempo foi construída utilizando timestamps e atributos derivados, como:

- Dia;
- Mês;
- Ano;
- Trimestre;
- Dia da semana;
- Semana epidemiológica.

3 Processo ETL

O processo ETL (Extract, Transform and Load) foi implementado para realizar a movimentação dos dados desde a fonte original até o Data Warehouse.

3.1 Extract

Os dados foram obtidos a partir do arquivo:

`MICRODADOS.csv`

contendo registros de notificações relacionadas à COVID-19.

3.2 Transform

Durante a transformação foram aplicados diversos tratamentos, incluindo:

- Remoção de espaços em branco;
- Tratamento de valores nulos;
- Padronização de textos;
- Conversão de datas;
- Criação de chaves substitutas;
- Criação de indicadores analíticos para confirmação, óbito, cura e internação.

Também foram criadas dimensões específicas para sintomas, comorbidades e testes realizados.

3.3 Load

Após as transformações, os dados foram carregados em três camadas:

Staging (stg)

Armazena os dados brutos importados do CSV.

Data Warehouse (dw)

Contém a modelagem dimensional composta pelas dimensões e tabela fato.

Data Mart (mart)

Reservado para consultas analíticas e futuras expansões.

O Data Warehouse final armazenou aproximadamente 5,2 milhões de registros na tabela fato.

4 Integração do Streamlit com o Data Warehouse

Na versão inicial do projeto, desenvolvida na etapa C1, o dashboard realizava a leitura direta do arquivo CSV através da biblioteca Pandas.

Exemplo:

```
pd.read_csv("MICRODADOS.csv")
```

Embora funcional, essa abordagem exigia que todo o conjunto de dados fosse carregado para a memória da aplicação a cada execução.

Na etapa C3, a aplicação foi adaptada para utilizar consultas SQL diretamente no Data Warehouse PostgreSQL.

Exemplo:

```
pd.read_sql(query, engine)
```

A conexão foi realizada através das bibliotecas:

- SQLAlchemy;
- Psycopg2.

Com isso, apenas os dados necessários para cada visualização passaram a ser carregados, reduzindo significativamente o tempo de processamento.

5 Dashboard Analítico

O dashboard desenvolvido em Streamlit passou a consumir os dados diretamente do Data Warehouse e disponibiliza as seguintes análises:

5.1 Indicadores Gerais

- Total de notificações;
- Total de casos confirmados;
- Total de óbitos;
- Total de curas.

5.2 Distribuição por Classificação

Apresenta a quantidade de registros por classificação dos casos.

5.3 Distribuição por Sexo

Apresenta a participação percentual dos registros de acordo com o sexo dos pacientes.

5.4 Evolução Temporal

Mostra a evolução das notificações ao longo do tempo.

5.5 Top Municípios

Apresenta os municípios com maior número de registros de notificações.

5.6 Indicadores de Letalidade

Permite acompanhar a taxa de letalidade dos casos confirmados.

6 Análise de Desempenho

Foi realizada uma comparação entre a versão baseada em CSV e a versão integrada ao Data Warehouse.

6.1 Resultados Obtidos

Método	Tempo de Carregamento
CSV	21,22 segundos
Data Warehouse PostgreSQL	0,56 segundos

Tabela 1: Comparação de desempenho entre CSV e Data Warehouse

6.2 Comparação

O uso do Data Warehouse apresentou desempenho aproximadamente 38 vezes superior ao carregamento direto do arquivo CSV.

Esse ganho ocorreu porque:

- Os dados já estão organizados em estrutura analítica;
- As consultas são processadas pelo SGBD;
- Apenas os resultados necessários são enviados à aplicação;
- Há redução do consumo de memória no Streamlit.

6.3 Escalabilidade

A solução baseada em Data Warehouse apresenta maior escalabilidade, sendo capaz de suportar volumes significativamente maiores de dados sem comprometer o desempenho do dashboard.

Enquanto a abordagem baseada em CSV tende a degradar à medida que o volume cresce, o banco de dados permite utilização de índices, otimizações internas e processamento distribuído de consultas.

7 Conclusão

O projeto permitiu aplicar conceitos fundamentais de Business Intelligence, incluindo modelagem dimensional, processos ETL, construção de Data Warehouses e desenvolvimento de dashboards analíticos.

A migração da leitura direta de arquivos CSV para consultas em um Data Warehouse PostgreSQL demonstrou ganhos expressivos de desempenho e escalabilidade, tornando a solução mais adequada para cenários reais de análise de dados.

Os resultados obtidos evidenciam a importância das técnicas de BI para transformar grandes volumes de dados em informações úteis para tomada de decisão, consolidando os conhecimentos desenvolvidos ao longo da disciplina.